



AGENTES MULTIMODELOS TIPO 5



Faculdade
Mar Atlântico



Certificação IA

SUMÁRIO

1. Introdução aos Agentes de Inteligência Artificial	3
1.1. Evolução e Complexidade dos Agentes	3
1.2. Tipologia Proposta de Agentes de IA	3
1.3. Desafios na Classificação dos Agentes.....	3
2. Definindo a Estrutura dos Agentes de IA	4
2.1. A Busca por uma Organização Clara: Interagindo com a IA.....	4
2.2. Categorização por Ativação, Capacidade Cognitiva e Estrutura	4
2.3. Representações Visuais: Diagramas e Modelos Ontológicos	5
3. O Agente Multimodelo em Ação	6
3.1. Conceito e Funcionamento do Agente Multimodelo	6
3.2. Demonstração Prática: Análise Colaborativa entre Modelos de IA	6
3.3. Vantagens da Abordagem Multimodelo	7
4. Aplicações Práticas de Agentes Multimodelo	7
4.1. Análise de Dados e o Papel do Deep Analysis	7
4.2. Foco em Análise Financeira	8
4.3. Construindo um Agente Multimodelo: Exemplo na Área de Vendas	8
4.3.1. Definição do Cenário e Papéis.....	8
4.3.2. Processamento de Documentos e Entradas.....	8
4.3.3. Integração de Múltiplos Modelos como “Gerentes”	9
4.3.4. O Papel do “Diretor” e a Consolidação da Análise	9
5. Avaliando o Desempenho de Modelos de IA: Um Estudo de Caso com Lógica	10
5.1. O Desafio Lógico Proposto.....	10
5.2. Testando Modelos Individuais (Single Models)	11
5.2.1. Configuração do Agente de Teste.....	11

1. Introdução aos Agentes de Inteligência Artificial

A jornada pelo universo da Inteligência Artificial (IA) nos conduz a patamares cada vez mais sofisticados de interação e autonomia. Neste material, exploraremos a conceituação e aplicação de agentes de IA, com ênfase particular nos agentes multimodelo, que representam uma fronteira promissora na capacidade das máquinas de processar e interagir com informações de diversas naturezas. A compreensão dessas tipologias é fundamental, não apenas para desenvolvedores e entusiastas da tecnologia, mas para todos que buscam entender o impacto transformador da IA em diversos setores.

1.1. Evolução e Complexidade dos Agentes

O desenvolvimento de agentes de IA tem seguido uma trajetória de crescente complexidade. Inicialmente, as interações eram mais simples, mas com o avanço das tecnologias e plataformas, como a Tess, tornou-se possível construir sistemas mais elaborados. A organização didática desses conceitos visa facilitar o aprendizado progressivo, introduzindo recursos e funcionalidades de maneira gradual e contextualizada. A tipologia aqui apresentada é fruto de extensa experiência prática na criação de IAs e automações, buscando uma estrutura lógica que permita acompanhar a evolução da complexidade e a introdução de recursos adicionais.

1.2. Tipologia Proposta de Agentes de IA

Ao longo desta exploração, consideraremos uma tipologia que abrange diferentes naturezas e funcionalidades dos agentes de IA. Chegamos a um ponto onde se faz necessário discutir o agente multimodelo, classificado como Tipo 5. Antes dele, foram apresentados:

- Agente de Chat (Tipo 1): Focado na interação conversacional.
- Agente Acionado por Evento (Tipo 2): Reage a gatilhos ou ocorrências específicas.
- Multiagentes Sequenciais (Tipo 3): Envolve múltiplos agentes operando em uma sequência definida.
- Agente Autônomo (Tipo 4): Possui capacidade de operar com maior independência, tomando decisões e executando ações sem intervenção humana constante.

Finalizando a tipologia, teremos os Multiagentes Autônomos (Tipo 6), que combinam as características de múltiplos agentes com alta autonomia.

1.3. Desafios na Classificação dos Agentes

É crucial observar que as categorias propostas não são mutuamente excludentes nem possuem a mesma natureza fundamental. As qualidades que definem cada tipo podem se

sobrepôr e interagir. Por exemplo, um agente de chat (Tipo 1) pode, concomitantemente, ser um agente autônomo (Tipo 4), como já explorado em contextos anteriores.

Da mesma forma, uma automação que envolve multiagentes sequenciais (Tipo 3) pode incorporar, em sua estrutura, agentes acionados por evento (Tipo 2), agentes multimodelo (Tipo 5) e até mesmo agentes de chat (Tipo 1). Se uma automação é composta por múltiplos agentes autônomos, ela se enquadra na categoria de multiagentes autônomos (Tipo 6). Essa interconexão de características evidencia a necessidade de uma abordagem mais granular para entender a arquitetura dos agentes de IA.

2. Definindo a Estrutura dos Agentes de IA

Para refinar a compreensão da tipologia dos agentes de IA, é útil adotar uma perspectiva que organize suas características em dimensões distintas. Essa abordagem permite acomodar a complexidade e as intersecções observadas.

2.1. A Busca por uma Organização Clara: Interagindo com a IA

A construção de uma tipologia clara e funcional muitas vezes se beneficia da própria ferramenta que se busca classificar: a Inteligência Artificial. Em um processo iterativo, utilizando um agente de chat na plataforma Tess, foi possível explorar diferentes formas de organizar os tipos de agentes. A inspiração inicial veio da teoria dos conjuntos, visualizada através de diagramas de Venn, onde os diferentes tipos de agentes seriam representados como conjuntos com possíveis intersecções.

Ao apresentar essa ideia à IA, explicando a tipologia e as características de cada agente, a plataforma começou a aplicar a teoria dos conjuntos, identificando relações e intersecções entre os Tipos 1, 2, 3 e 6. Esse processo envolveu a identificação de símbolos de intersecção e a montagem de tabelas que resumiam as inclusões e sobreposições. Foi utilizado, nesse caso, o modelo GPT-4 mais recente. Um ponto crucial dessa interação foi a instrução para que a IA perguntasse caso identificasse alguma intersecção ou relação faltante, o que levou a um diálogo produtivo e ao refinamento das definições. Após responder às perguntas da IA, solicitou-se um resumo visual em palavras, o que facilitou a compreensão da estrutura emergente. A IA, então, sugeriu a criação de diagramas, tanto de Venn quanto em formato de gráfico, para ilustrar as relações.

Contudo, a representação visual inicial, especialmente o diagrama de Venn gerado automaticamente, não se mostrou satisfatória. A tentativa de agrupar todos os tipos, incluindo o Tipo 5 (multimodelo) e o Tipo 6 (multiagentes autônomos), dentro da lógica estrita da teoria dos conjuntos revelou-se inadequada, pois, como mencionado, os tipos não compartilham a mesma natureza fundamental. A teoria dos conjuntos, embora útil inicialmente, enviou a IA para uma estrutura que não capturava plenamente as distinções qualitativas.

2.2. Categorização por Ativação, Capacidade Cognitiva e Estrutura

Percebendo as limitações da abordagem anterior, a questão foi reformulada para a IA: qual a melhor forma de organizar essa tipologia, considerando que os tipos parecem possuir naturezas distintas? A IA, então, propôs uma classificação mais hierárquica e multidimensional, que se mostrou muito mais eficaz:

Ativação ou Comportamento: Esta dimensão descreve como o agente é iniciado ou como ele interage. As subcategorias aqui são:

- Chat: Agentes baseados em conversação.
- Acionado por Evento: Agentes que respondem a gatilhos específicos.
- Autônomo: Agentes com maior grau de independência em suas operações.

Capacidade Cognitiva: Refere-se às habilidades de processamento e compreensão do agente. É aqui que se encaixa o conceito de:

Multimodelo: Agentes capazes de processar e integrar informações de múltiplas modalidades (texto, imagem, áudio, etc.). Essa capacidade pode estar presente em qualquer um dos tipos de ativação.

Estrutura: Descreve a arquitetura do sistema de agentes. As subcategorias são:

Agente Único: Um sistema composto por um único agente.

Multiagente: Um sistema composto por múltiplos agentes. Dentro desta categoria, temos:

Sequencial (Tipo 3): Múltiplos agentes que operam em uma sequência definida.

Autônomos (Tipo 6): Múltiplos agentes autônomos colaborando.

Essa estrutura hierárquica e multidimensional oferece um lugar mais claro para cada tipo de agente ou automação, reconhecendo que características como “multimodelo” são, na verdade, uma capacidade cognitiva que pode permear diferentes formas de ativação e estruturas.

2.3. Representações Visuais: Diagramas e Modelos Ontológicos

Com essa nova estrutura conceitual, a IA foi capaz de gerar representações visuais mais elucidativas. Solicitou-se a criação de um “modelo ontológico leve”, uma representação gráfica que organiza os conceitos e suas relações. Utilizando o modelo GPT-4O com o recurso de Deep Analysis (necessário para a geração de imagens), a IA produziu um diagrama que dispunha as dimensões em camadas:

Níveis de Ativação e Comportamento (camada superior).

Capacidade Cognitiva (camada intermediária, destacando o multimodelo).

Estrutura Multiagente (camada inferior).

Essa representação visual organizou de forma clara e elegante a tipologia. Para obter validações adicionais e explorar outras perspectivas, a mesma tarefa foi solicitada a outros modelos de IA, como o Claude 3.7 Sonnet. Este modelo gerou um material ainda mais elaborado, quase um documento pronto, intitulado “Tipologia de Automação de Agente GA: Estrutura Hierárquica e Matriz de Características”. Este documento apresentava as dimensões de ativação, cognitiva e estrutural de forma visualmente rica, utilizando linhas tracejadas e setas para indicar hierarquias, aplicação de atributos e relações de composição. Detalhava cada tipo de agente, suas características de ativação, a possibilidade de ser multimodelo e sua estrutura (individual ou composta).

Posteriormente, o modelo Grok3 foi desafiado com a mesma tarefa. Inicialmente, houve uma dificuldade na geração de um link para download da imagem, o que foi contornado instruindo o modelo a utilizar seu recurso de execução de código (Deep Analysis) para gerar o arquivo. O Grok3 produziu um “Diagrama de Fluxo Piramidal da Tipologia de Agente”, que também ofereceu uma perspectiva interessante e simplificada, organizando os conceitos em estrutura de execução, capacidade cognitiva e ativação. Embora todas as representações fossem válidas, a gerada pelo Claude 3.7 Sonnet destacou-se pela clareza e detalhamento.

3. O Agente Multimodelo em Ação

A interação descrita acima, onde diferentes modelos de IA foram utilizados para analisar, refinar e gerar representações de um conceito, é, em si, uma demonstração prática do princípio do agente multimodelo.

3.1. Conceito e Funcionamento do Agente Multimodelo

Um agente multimodelo, no contexto explorado, refere-se à capacidade de um sistema de IA utilizar os outputs (resultados) de um ou mais modelos de IA como inputs (entradas) para outro modelo, visando um raciocínio mais robusto e uma resposta final mais elaborada. Isso é diferente de um sistema multiagente sequencial simples, onde, por exemplo, um agente transcreve um áudio e o texto resultante é passado para outro agente analisar. No caso do multimodelo, a ênfase está no aprimoramento do processo de raciocínio do agente final, que considera as “análises” ou “conclusões” de outros modelos para formar sua própria.

Essa abordagem é particularmente poderosa quando há uma forte dependência entre as conclusões dos modelos intermediários para a geração de um resultado final de alta qualidade. O agente principal não está apenas processando dados brutos, mas sim “refletindo” sobre as interpretações de outros agentes.

3.2. Demonstração Prática: Análise Colaborativa entre Modelos de IA

No processo de definição da tipologia dos agentes, foi utilizado o AI Copilot da plataforma Tess. Inicialmente, um modelo (GPT-4O) foi usado para gerar uma estrutura. Em seguida, foi instruído: “Agora interprete toda a conversa, analise com calma e confira se esta é a forma adequada. Não estou dizendo se está certo ou errado. Quero duplas validações. Ao final, gere a imagem no formato que julgar mais adequado.” Essa instrução foi passada para outro modelo (Claude 3.7 Sonnet), que então processou todo o histórico da conversa, incluindo os outputs do GPT-4O, para gerar sua própria análise e representação visual. O mesmo processo foi repetido com o Grok3.

Essa capacidade de “passar o bastão” entre modelos, onde cada um contribui com sua perspectiva e capacidade de processamento, enriquece o resultado final. A ativação ou desativação do recurso de Deep Analysis era feita conforme a necessidade de gerar arquivos (como imagens) ou apenas trocar ideias textuais.

3.3. Vantagens da Abordagem Multimodelo

A principal vantagem do agente multimodelo reside na sua capacidade de alcançar um nível de análise e conclusão que pode superar o de um único modelo operando isoladamente. Ao simular um processo de consulta a múltiplos “especialistas” (os diferentes modelos de IA), o agente final pode identificar nuances, validar informações e sintetizar perspectivas diversas.

Essa capacidade é especialmente relevante em tarefas complexas, como análise de dados, onde a interpretação de resultados numéricos ou lógicos se beneficia de múltiplas “opiniões” ou abordagens de raciocínio. A plataforma Tess permite essa flexibilidade diretamente na interface de chat, sem a necessidade de criar formalmente um agente complexo no Studio para cada interação desse tipo. Com o Deep Analysis, é possível anexar documentos e planilhas extensas, ampliando o escopo de aplicação dos agentes multimodelo.

4. Aplicações Práticas de Agentes Multimodelo

A capacidade dos agentes multimodelo de integrar e processar informações de diversas fontes e naturezas abre um vasto leque de aplicações, especialmente em áreas que demandam análise complexa e tomada de decisão informada.

4.1. Análise de Dados e o Papel do Deep Analysis

Uma das áreas mais promissoras para a aplicação de agentes multimodelo é a análise de dados. Frequentemente, ouve-se que IAs generativas não são inerentemente boas em realizar cálculos precisos. Embora isso seja verdade para o processamento generativo puro, a combinação da IA generativa com recursos como o Deep Analysis transforma esse cenário. O Deep Analysis permite que a IA gere e execute códigos (por exemplo, em Python) para realizar cálculos, processar grandes volumes de dados (como arquivos CSV) e

manipular informações de forma estruturada. O resultado desse processamento de código é, então, fornecido à IA generativa para interpretação, resumo e apresentação em um formato conversacional.

Isso permite que se mantenha uma interação fluida e intuitiva com a IA, enquanto, nos bastidores, cálculos complexos e processamento de dados estão sendo realizados com precisão por meio de código. Essa sinergia é fundamental para tarefas que envolvem números, lógica e a necessidade de extrair insights de conjuntos de dados.

4.2. Foco em Análise Financeira

Dada a robustez da abordagem multimodelo combinada com o Deep Analysis, a área financeira surge como um campo natural de aplicação. O departamento financeiro de empresas, ou a área de finanças como um todo, lida intensamente com números, planilhas, relatórios e a necessidade de análises precisas e interpretações lógicas. Agentes multimodelo podem ser empregados para analisar demonstrativos de resultados, balanços patrimoniais, fluxos de caixa, e auxiliar na tomada de decisões de investimento, planejamento financeiro e controladoria.

4.3. Construindo um Agente Multimodelo: Exemplo na Área de Vendas

Para ilustrar a construção de um agente multimodelo, consideremos um caso de uso na área de vendas, onde se deseja analisar o desempenho de vendedores e a qualidade das análises feitas por gerentes de vendas. O objetivo é criar um agente que atue como um “diretor de vendas”, avaliando tanto as interações comerciais dos vendedores quanto as análises de seus respectivos gerentes.

4.3.1. Definição do Cenário e Papéis

O agente principal (o “diretor de vendas”) será configurado para utilizar um modelo de IA específico (por exemplo, GPT-4O). Este agente receberá como input análises de reuniões comerciais de vendedores B2B, que foram previamente realizadas por diferentes “gerentes de vendas”. Cada “gerente de vendas”, neste contexto, será representado por um modelo de IA diferente (por exemplo, Claude Opus, Gemini Pro, Llama).

O prompt inicial para o agente “diretor de vendas” seria algo como:

“Atue como um diretor de vendas. Abaixo estão as análises de reuniões comerciais de vendedores B2B. Essas análises foram feitas por diferentes gerentes de vendas. Como diretor, analise todas as reuniões de cada vendedor de forma individual. Tire suas próprias conclusões. Analise as análises dos gerentes. E, por fim, gere um relatório sobre o desempenho dos gerentes, atribuindo uma nota para o nível de senioridade que demonstraram em suas análises.”

4.3.2. Processamento de Documentos e Entradas

Para fornecer as informações necessárias, o agente precisará de acesso às transcrições das reuniões comerciais e às análises dos gerentes. As transcrições das reuniões de cada vendedor podem ser compiladas em um único arquivo PDF. Este PDF será fornecido como uma entrada de arquivo (File Input) para o agente.

Dentro da plataforma Tess, o upload de um arquivo PDF pode ser seguido por um step de processamento de documentos (Document Processing), como “Extrair Texto de PDF Inteiro”. O output deste step será o conteúdo textual do PDF, que contém as transcrições.

4.3.3. Integração de Múltiplos Modelos como “Gerentes”

As análises dos “gerentes de vendas” serão geradas utilizando steps de AI Assistant dentro da configuração do agente principal. Para cada “gerente”, um modelo de IA diferente será selecionado:

- Gerente “GPT” (Maria): Utilizará um modelo da família GPT (ex: Claude 3 Haiku, para variar e simular diferentes níveis de senioridade ou custo-benefício). O prompt para este gerente será: “Analise cada uma das reuniões comerciais presentes no [conteúdo do PDF das reuniões]. Elabore sua análise com base na metodologia X, considerando os critérios Y e Z. Apresente suas conclusões sobre o desempenho de cada vendedor.”
- Gerente “Claude” (José): Utilizará um modelo da família Claude (ex: Claude 3 Opus, um modelo poderoso). Receberá o mesmo prompt detalhado.
- Gerente “Gemini” (Ana): Utilizará um modelo da família Gemini (ex: Gemini 1.5 Pro). Receberá o mesmo prompt detalhado.

Os outputs desses steps de AI Assistant serão as análises individuais de cada “gerente”.

4.3.4. O Papel do “Diretor” e a Consolidação da Análise

O agente principal (“diretor de vendas”, rodando no GPT-4O) receberá, em seu prompt final, tanto as transcrições originais das reuniões (o conteúdo do PDF) quanto as análises geradas pelos “gerentes” Maria, José e Ana. O prompt seria estruturado da seguinte forma:

“Atue como um diretor de vendas.

Aqui estão as transcrições das reuniões para sua análise:

[Conteúdo do PDF das reuniões]

Abaixo estão as análises dessas reuniões, feitas por seus gerentes de vendas:

Análise da Gerente Maria (GPT):

[Output da análise do Gerente “GPT”]

Análise do Gerente José (Claude):

[Output da análise do Gerente “Claude”]

Análise da Gerente Ana (Gemini):

[Output da análise do Gerente “Gemini”]

Como diretor, analise todas as reuniões de cada vendedor de forma individual, com base nas transcrições fornecidas. Tire suas próprias conclusões sobre o desempenho dos vendedores. Em seguida, analise criticamente as análises dos gerentes Maria, José e Ana. Por fim, gere um relatório conciso sobre o desempenho dos gerentes, atribuindo uma nota de 0 a 10 para o nível de senioridade que demonstraram em suas análises, justificando cada nota.”

Desta forma, o agente “diretor de vendas” (GPT-4O) não apenas analisa o material original, mas também avalia o trabalho de outros modelos de IA, simulando uma estrutura hierárquica de gestão e análise. Este exemplo demonstra como um único agente de chat pode orquestrar o trabalho de múltiplos modelos para produzir uma resposta final rica e multifacetada, caracterizando a essência do agente multimodelo. A criação formal de um agente no Studio da Tess é vantajosa para casos de uso repetitivos, onde apenas o arquivo de input ou pequenas notas são alteradas a cada execução.

5. Avaliando o Desempenho de Modelos de IA: Um Estudo de Caso com Lógica

Para demonstrar concretamente o potencial e a força da abordagem multimodelo, é instrutivo realizar testes comparativos entre modelos de IA individuais (single models) e uma configuração multimodelo. Um desafio lógico simples pode servir como um campo de provas eficaz para essa análise.

5.1. O Desafio Lógico Proposto

Considere o seguinte enigma:

“Se Banana é 3, Uva é 3, Mamão é 3, então Figo é ?”

As opções de múltipla escolha podem ser:

- a) 2
- b) 3
- c) 4
- d) 5

A solução para este enigma reside na contagem do número de letras distintas em cada palavra.

Banana (b, a, n) = 3 letras distintas.

Uva (u, v, a) = 3 letras distintas.

Mamão (m, a, o - considerando ‘ã’ como ‘a’ para fins de distinção de letra fundamental do alfabeto) = 3 letras distintas.

Portanto, Figo (f, i, g, o) possui 4 letras distintas. A resposta correta é 4 (opção c).

Este tipo de desafio, que envolve lógica e um certo grau de interpretação linguística (como a questão do 'ã'), é interessante para testar a capacidade de raciocínio dos modelos de IA.

Antes de prosseguir com o teste lógico, é importante recapitular e corrigir um ponto sobre a construção do agente multimodelo de vendas mencionado anteriormente. Para que o agente funcione corretamente, a entrada de arquivo (o PDF com as reuniões) deve ser processada para extrair seu conteúdo textual antes de ser passada para os AI Assistants. Ou seja, o fluxo correto no Studio da Tess seria: 1. User Input (File Input para o PDF). 2. Document Processing (Extrair texto do PDF). 3. Múltiplos AI Assistants (os "gerentes"), cada um recebendo o "texto do PDF" como input para suas análises. 4. O AI Assistant principal (o "diretor") recebe o "texto do PDF" e os outputs dos gerentes.

5.2. Testando Modelos Individuais (Single Models)

O primeiro passo para avaliar a hipótese da superioridade do multimodelo é testar o desempenho de diversos modelos de IA individualmente frente ao desafio lógico.

5.2.1. Configuração do Agente de Teste

Um agente simples foi criado na plataforma Tess com o seguinte prompt: "Atue como especialista em questões de lógica. Você sempre receberá questões de múltipla escolha. Responda apenas com a letra e o respectivo valor no formato: Letra, Valor (ex: C, 4)." O modelo de IA para este agente foi deixado como uma escolha variável, permitindo testar diferentes motores (GPT-4 latest, DeepSeek Reasoning, DeepSeek V3, GPT-4.1 Nano, GPT-4.1 Mini, Grok3Fest, Llama3.1, CommandR, etc.). O nível de criatividade (temperatura) foi fixado em 1 para consistência.

Ao submeter o enigma a esses modelos individualmente, observou-se uma variação significativa nas respostas e nos processos de raciocínio:

GPT-4 latest: Após tentar várias abordagens (número de letras, sílabas, letras repetidas, consoantes, vogais), finalmente identificou o padrão de letras distintas (considerando 'a' e 'ã' como a mesma letra base) e acertou a resposta (4).

DeepSeek Reasoning: Também identificou o padrão correto e acertou.

DeepSeek V3: Errou, propondo uma lógica incorreta baseada em vogais repetidas que não se sustentava para todos os exemplos.

GPT-4.1 Nano: Errou.

GPT-4.1 Mini: Acertou, identificando rapidamente o padrão de letras distintas.

Grok3Fest: Errou.

Llama3.1: Errou, sem apresentar justificativa.

CommandR: Errou.

Essa amostragem inicial já indica que nem todos os modelos conseguem resolver o problema, e mesmo os que acertam podem seguir caminhos de raciocínio diferentes.

5.2.2. A Importância da Análise Estatística e os Perigos de Conclusões Precipitadas

Com base em apenas uma ou poucas execuções para cada modelo, seria prematuro e estatisticamente inválido concluir qual modelo é “melhor” ou “pior” para este tipo de tarefa. É comum encontrar análises superficiais ou opiniões baseadas em testes limitados, o que pode levar a generalizações equivocadas sobre as capacidades dos modelos de IA.

Para uma avaliação robusta, é necessário um teste em massa, com múltiplas execuções para cada modelo sob as mesmas condições (mesmo prompt, mesma temperatura). A plataforma Tess facilita esse tipo de teste comparativo, permitindo alternar rapidamente entre modelos em uma mesma conversa ou criar agentes específicos para cada um.

5.2.3. Metodologia de Teste em Massa via Planilha e Scripts

Para realizar o teste em massa de forma organizada, foi utilizada uma planilha do Google Sheets. A planilha foi estruturada com as seguintes colunas:

Run: Identificador da execução.

Pergunta de Lógica: O enigma proposto.

Modelo: O modelo de IA a ser testado (selecionável de uma lista).

Resposta do Agente: Campo a ser preenchido pela IA.

Gabarito: A resposta correta (ex: “C, 4” ou apenas “4”, dependendo do ajuste no prompt do agente).

Pontuação: 1 se a resposta do agente for igual ao gabarito, 0 caso contrário.

Um script do Google Apps Script foi desenvolvido (com auxílio da própria IA da Tess, fornecendo a documentação da API como base de conhecimento) para automatizar o processo. O script permite:

- Marcar em uma checkbox quais linhas da planilha (combinações de pergunta e modelo) devem ser executadas.
- Para cada linha marcada, o script chama a API da Tess, executando o agente de lógica com o modelo especificado.
- A resposta do agente é automaticamente inserida na coluna “Resposta do Agente” da planilha.
- A pontuação é calculada automaticamente.

Essa automação permite realizar centenas de testes de forma eficiente. Para este estudo, cada modelo selecionado foi testado 50 vezes com a mesma pergunta de lógica. O

agente de teste foi ajustado para retornar apenas o número da resposta (ex: “4”) para simplificar a validação.

5.3. Resultados dos Testes com Modelos Individuais

Após a execução dos testes em massa (50 vezes para cada modelo selecionado), os resultados foram compilados e analisados.

5.3.1. Análise Quantitativa dos Acertos

Os modelos apresentaram taxas de acerto variadas:

GPT-4.1: Desempenho elevado.

Claude 3.7 Sonnet latest/thinking: Desempenho elevado.

Gemini 2.0 Flash: Desempenho intermediário, com alguns erros.

Grok3 Translated: Taxa de acerto muito baixa (1 acerto em 50).

DeepSeek R1: Taxa de acerto muito baixa.

Llama: Taxa de acerto muito baixa (1 acerto em 50).

GPT-4.1 Mini: Nenhum acerto em 50 execuções.

GPT-4O latest: Taxa de acerto muito baixa (1 acerto em 50).

É importante notar que erros de API ou timeouts podem ocorrer em algumas execuções, o que é normal. Nesses casos, a execução pode ser repetida para garantir a coleta do dado.

5.3.2. O Campeão entre os Modelos Individuais

Para visualizar melhor os resultados, um outro script (apelidado de “John Brown Run”, em homenagem a um pioneiro da estatística) foi criado para processar os dados da planilha e gerar uma tabela resumo e um gráfico comparativo das taxas de acerto.

Após 50 execuções, o GPT-4.1 e o Claude 3.7 Sonnet Thinking empataram com 46 acertos (92% de taxa de acerto). Para desempatar, uma execução adicional (a 51ª) foi realizada para ambos. O GPT-4.1 errou, enquanto o Claude 3.7 Sonnet Thinking acertou.

Portanto, para este específico teste de lógica, executado 51 vezes, o Claude 3.7 Sonnet Thinking emergiu como o modelo individual com a maior taxa de acerto (47 de 51, aproximadamente 92.15%).

É fundamental reiterar que este resultado é específico para o teste realizado. A superioridade de um modelo em uma tarefa não garante sua superioridade em todas as outras. Testes contínuos e específicos para cada caso de uso são necessários para determinar o modelo mais adequado.

5.4. O Agente Multimodelo no Teste de Lógica

Com os resultados dos modelos individuais em mãos, o próximo passo é testar uma abordagem multimodelo para o mesmo desafio lógico, com a hipótese de que ela superará o melhor modelo individual.

5.4.1. Configuração do Agente Multimodelo com “Patinhos Feios”

Para tornar o teste mais rigoroso e interessante, o agente multimodelo foi configurado utilizando modelos que tiveram desempenho individual muito baixo (os “patinhos feios”):

Aluno “GPetinho”: GPT-4.1 Mini (0% de acerto individual).

Aluno “GPetão”: GPT-4O latest (2% de acerto individual).

Aluno “Alpaca”: Um modelo da família Llama (2% de acerto individual).

O agente principal (o “professor de lógica”) foi configurado para usar o GPT-4O latest (que também teve baixo desempenho individualmente). O prompt do agente principal foi:

“Atue como um professor de lógica com mais de 30 anos de experiência. A questão é: ‘Se Banana é 3, Uva é 3, Mamão é 3, então Figo é ?’. Abaixo estão os raciocínios e respostas de seus alunos:

Raciocínio e Resposta do Aluno GPetinho: [Output do GPT-4.1 Mini para a questão]

Raciocínio e Resposta do Aluno GPetão: [Output do GPT-4O latest para a questão]

Raciocínio e Resposta do Aluno Alpaca: [Output do Llama para a questão]

Com base nos raciocínios e respostas de seus alunos, e em seu próprio vasto conhecimento, qual é a resposta correta para Figo? Retorne apenas o número. Adicionalmente, traga em formato JSON a sua justificativa enxuta, as respostas de cada aluno (GPetinho, GPetão, Alpaca) e o número correspondente ao Figo (sua resposta final).”

A ideia é que o GPT-4O latest, atuando como professor, analise as tentativas (provavelmente erradas) de seus “alunos” e, usando essas múltiplas perspectivas (mesmo que falhas), chegue à conclusão correta. O formato de saída JSON foi solicitado para facilitar a extração de dados e análises posteriores. Para garantir a extração correta dos diferentes campos do JSON, especialmente a justificativa e as respostas individuais, o prompt foi ajustado para que a IA separasse esses elementos com um delimitador específico (ex: “|||”) na sua saída, facilitando o parsing posterior.

5.4.2. Execução e Resultados do Agente Multimodelo

O agente multimodelo foi executado 50 vezes. Inicialmente, houve alguns problemas na formatação da saída quando se utilizava ponto e vírgula como separador no script de parsing, pois as justificativas dos modelos podiam conter esse caractere. Ao ajustar para um separador mais robusto (como “|||”) e refinar a lógica de extração, os resultados foram consistentes.

Considerando as primeiras 50 execuções (mesmo com alguns erros de parsing inicial

que foram posteriormente investigados e confirmados como acertos lógicos do modelo, mas falhas na extração), o agente multimodelo alcançou 47 acertos, empatando com o Claude 3.7 Sonnet.

No entanto, após o ajuste do separador e a execução de um novo lote de 50 testes, o agente multimodelo acertou 100% das vezes. Mesmo quando os “alunos” (GPT-4.1 Mini, GPT-4O, Llama) erravam consistentemente, o GPT-4O latest, no papel de “professor” analisando essas múltiplas entradas, conseguiu identificar o padrão correto em todas as execuções.

5.4.3. Comprovação da Superioridade da Abordagem Multimodelo

Os resultados demonstram de forma contundente a superioridade da abordagem multimodelo para este problema específico. Um conjunto de modelos com baixo desempenho individual, quando orquestrado por um modelo supervisor (mesmo que este também tenha tido baixo desempenho individualmente), conseguiu atingir uma taxa de acerto perfeita. Isso sugere que a capacidade de analisar múltiplas linhas de raciocínio, mesmo que incorretas, pode levar a uma síntese mais precisa e robusta.

5.5. Métodos Alternativos para Execução de Testes em Massa

Além do método de script direto no Google Apps Script, outras abordagens podem ser utilizadas para executar testes em massa e automações envolvendo agentes da Tess.

5.5.1. Utilização de Webhooks e Plataformas de Automação (Zapier)

Uma alternativa é usar o Google Apps Script para disparar um webhook. Esse webhook ativa um fluxo (um “Zap”) na plataforma de automação Zapier. O Zap, por sua vez, executa o agente da Tess (neste caso, o agente multimodelo de lógica) via API. Como a execução do agente multimodelo pode ser mais demorada, utiliza-se um step de “long run” no Zapier, que aguarda a conclusão. A resposta do agente é então coletada pelo Zapier, que pode formatá-la (ex: dividindo o texto com base no separador “|||”) e, finalmente, atualizar a planilha do Google Sheets com os resultados.

A vantagem desta abordagem é a maior facilidade de registro (logs), depuração e gerenciamento de execuções paralelas que plataformas como o Zapier oferecem. O script na planilha apenas inicia o processo, e o Zapier cuida da orquestração mais complexa. A desvantagem é a introdução de mais uma plataforma e, potencialmente, custos adicionais.

5.5.2. Execução Direta na Plataforma Tess com Deep Analysis

Uma terceira via, cada vez mais poderosa, é realizar todo o processo dentro de um único chat na plataforma Tess, utilizando o recurso de Deep Analysis. Pode-se instruir um modelo como o Claude 3.7 Sonnet (ou outro com capacidade de Deep Analysis) a:

- Atuar como um desenvolvedor sênior.
- Utilizar a documentação da API da Tess (fornecida no prompt ou como base de conhecimento).
- Executar o agente multimodelo de lógica N vezes (ex: 5 vezes).
- Coletar os resultados.
- Gerar uma tabela com os resultados, um arquivo CSV, e até mesmo um gráfico resumindo os tempos de resposta ou taxas de acerto.

Nesse cenário, o Deep Analysis permite que a IA gere e execute código Python para interagir com a API da Tess, realizar os testes e processar os resultados, tudo de forma conversacional. Isso elimina a necessidade de planilhas externas ou plataformas de automação para muitos cenários de teste e análise. A própria máquina virtual gerada pela Tess para rodar o código Python chama a API da Tess, criando um ciclo de autoanálise e execução.

Este estudo de caso, com o simples enigma da banana, ilustra não apenas a variabilidade no desempenho dos modelos de IA, mas principalmente o poder da abordagem multimodelo e as diversas ferramentas disponíveis para testar, validar e implementar essas soluções.

6. Aplicações Avançadas de Agentes Multimodelo na Área Financeira

A robustez demonstrada pelos agentes multimodelo, especialmente quando combinada com capacidades como o Deep Analysis, abre um vasto campo de aplicações no setor financeiro, onde a precisão, a análise de grandes volumes de dados e a interpretação de informações complexas são cruciais.

6.1. Análise de Demonstrativos Financeiros (DRE)

A análise de Demonstrativos do Resultado do Exercício (DRE), balanços patrimoniais e outros relatórios financeiros é uma tarefa fundamental para investidores, analistas e gestores. Agentes de IA podem ser configurados para auxiliar nesse processo.

6.1.1. Configuração do Agente Analista Financeiro (Versão 1 - Single Model)

Inicialmente, pode-se criar um agente utilizando um único modelo (por exemplo, Claude 3.7 Sonnet com Deep Analysis ativado). O prompt definiria o papel do agente:

“Você é um especialista financeiro da área de controladoria e contabilidade. Abaixo está o demonstrativo financeiro de uma empresa [nome da empresa, por exemplo, Lojas Renner,

Apple, CCR]. Faça uma análise completa deste documento para entender a situação financeira da empresa. Para lhe ajudar, abaixo há definições sobre os seguintes indicadores financeiros [listar indicadores como ROE, margem bruta, liquidez corrente, etc.]. Priorize-os e complemente de acordo com o demonstrativo. Ao final, pergunte ao usuário se ele quer uma análise mais específica para um determinado tipo de indicador.”

O agente receberia como input o arquivo PDF do demonstrativo financeiro. Utilizaria o Deep Analysis para processar o documento e, em seguida, geraria uma análise textual, abordando estrutura patrimonial, liquidez, desempenho operacional, rentabilidade, eficiência e outros aspectos relevantes, com base nos indicadores fornecidos.

6.1.2. Análise Qualitativa e Quantitativa com Deep Analysis

A IA generativa, por si só, é mais adequada para a análise descritiva e interpretativa. Para cálculos precisos, o Deep Analysis entra em cena. Pode-se solicitar ao agente: “Agora, refaça essa análise, executando cálculos através do Deep Analysis para os principais indicadores.” A IA então geraria código Python para extrair os dados numéricos do relatório e calcular os indicadores solicitados, apresentando-os de forma organizada, possivelmente com gráficos gerados pela biblioteca Matplotlib ou similar.

Um exemplo de interação seria: “Considerando uma análise fundamentalista e o setor da empresa no Brasil, e tendo como referência investidores como Warren Buffett e Peter Lynch, e empresas como BlackRock, você acredita que vale a pena comprar ações desta empresa?” A IA, utilizando seu conhecimento e o Deep Analysis para extrair dados, forneceria uma análise sob a ótica desses investidores, considerando vantagens competitivas, solidez financeira, e outros fatores relevantes.

6.1.3. Geração de Relatórios e Planilhas Detalhadas

Para validação e uso prático, é fundamental que os cálculos e as análises possam ser auditados. Uma solicitação como: “Agora gere uma planilha em Excel contendo as fórmulas e os gráficos para que eu possa comprovar que seus cálculos desta análise estão corretos. Crie uma planilha organizada com os gráficos em abas exclusivas e as abas necessárias com os dados tabulares,” levaria o Deep Analysis a produzir um arquivo Excel (.xlsx) completo, com dados, fórmulas, gráficos e a explicação de cada aba. Isso transforma a IA em uma poderosa assistente para a área financeira, capaz de automatizar a geração de relatórios complexos.

6.2. Agente Multimodelo para Tomada de Decisão de Investimentos (Versão 2)

Elevando a complexidade, um agente multimodelo pode ser construído para simular um comitê de investimento.

6.2.1. Definição de Papéis: Gestor de Fundo e Assessores (Modelos de IA)

O agente principal atuaria como “Gestor de um Fundo de Investimento” (ex: “Tess Capital”), utilizando um modelo robusto como o Claude 3.7 Sonnet. Seus “assessores de investimento” seriam outros modelos de IA:

Assessor “George”: GPT-4.1 (com foco em análise fundamentalista).

Assessor “Ji”: Gemini 2.0 Flash Thinking (com foco em análise de dados financeiros).

Assessor “Jim”: DeepSeek R1 (com foco em aspectos específicos ou comparativos).

O prompt do gestor seria: “Atue como gestor do fundo Tess Capital. Abaixo está o demonstrativo financeiro de uma empresa listada na B3. Faça uma análise completa. Considere as análises dos assessores de investimento George, Ji e Jim [que seriam outputs de steps anteriores, cada um analisando o DRE com seu prompt específico]. Chegue a uma conclusão final, decidindo se é para comprar mais ações ou vender as que já possui. Seu output deve ser em formato JSON, trazendo: DecisaoFinal, JustificativaFinal, DecisaoGeorge, JustificativaGeorge, DecisaoJi, JustificativaJi, DecisaoJim, JustificativaJim. As justificativas devem ter o tamanho de um tweet.”

6.2.2. Consolidação da Análise e Decisão Final (Comprar/Vender)

O gestor (Claude 3.7 Sonnet) analisaria o DRE original e as conclusões de seus assessores, ponderando os diferentes pontos de vista para chegar a uma decisão final (comprar, vender, manter) e uma justificativa concisa. Este processo espelha a dinâmica de tomada de decisão em ambientes financeiros reais, onde múltiplas opiniões são consideradas.

6.2.3. Geração de Conteúdo Visual (Ex: Story para Redes Sociais)

Como um complemento, poderia ser solicitado ao agente (utilizando Deep Analysis) a geração de um resumo visual da decisão, como um story para Instagram, apresentando a decisão do fundo, a justificativa e, opcionalmente, as opiniões dos assessores. Isso demonstra a capacidade multimodelo de não apenas analisar, mas também comunicar informações de forma adaptada a diferentes mídias.

6.3. Análise Gráfica de Ativos Financeiros (Criptomoedas)

A análise gráfica, ou análise técnica, é outra área onde os agentes de IA, especialmente os multimodelo, podem oferecer grande valor, atuando como mentores ou assistentes para traders e investidores.

6.3.1. Introdução à Análise Gráfica e Ferramentas (TradingView)

Plataformas como o TradingView são amplamente utilizadas para visualizar gráficos de preços de diversos ativos (ações, criptomoedas, futuros) e aplicar indicadores técnicos como Médias Móveis (MA), Índice de Força Relativa (RSI), MACD, Bandas de Bollinger, etc. Esses indicadores ajudam a identificar tendências, pontos de suporte e resistência, e possíveis momentos de compra ou venda. Alguns indicadores, como o “AI Moving Average” disponível no TradingView, já incorporam elementos de IA em seus cálculos, e seus códigos-fonte (em PineScript, por exemplo) podem ser acessados e até mesmo analisados ou modificados com o auxílio de IAs generativas.

6.3.2. Configurando um Agente para Análise de Imagens de Gráficos

Uma abordagem para que a IA analise um gráfico é fornecer um print screen (captura de tela) do gráfico como uma imagem. Um agente pode ser configurado utilizando um step de AI Visual Media Insights (por exemplo, com Gemini Image Description) para extrair informações da imagem. O prompt seria: “Atue como um tutor em análise gráfica e dono de um fundo de investimento chamado Tess Capital, com perfil arrojado. Analise o gráfico do ativo anexo [imagem do gráfico], considere todas as informações (preço, indicadores, padrões de candlestick) e traga uma avaliação sobre o ativo: tendência (alta, baixa, lateral), momento (compra, venda, aguardar), e se falta algum outro gráfico ou indicador para complementar a análise.”

O modelo de visão (Gemini) descreveria a imagem detalhadamente, e essa descrição seria então utilizada por um modelo de linguagem para a análise técnica.

6.3.3. O Agente Multimodelo como Mentor em Análise Gráfica

Para uma análise mais profunda, uma estrutura multimodelo em cascata pode ser implementada:

Input: Imagem do gráfico (ex: Bitcoin/USD ou Ethereum/USD do TradingView).

Análise da Imagem (“Gia”): Gemini 1.5 Flash (via AI Visual Media Insights) descreve a imagem em detalhes (gráficos, indicadores, números visíveis). O prompt foca em extrair verbatim todos os detalhes.

Primeira Análise Técnica (“George”): GPT-4.1 recebe a descrição da imagem feita por “Gia” e realiza uma análise técnica inicial, considerando o perfil do fundo.

Segunda Análise Técnica e Consolidação (“Cláudio”): Claude 3.7 Sonnet Thinking (ou outro modelo de reasoning) recebe a descrição original da imagem (“Gia”) e a análise de “George”. Ele então realiza sua própria análise, aprofundando aspectos, considerando o perfil sênior e arrojado solicitado, e pode até mesmo identificar padrões mais complexos (ex: padrão Wyckoff). O modelo de reasoning pode detalhar seu processo de pensamento, mostrando como ele integra as informações anteriores e adiciona sua própria perspectiva.

(Opcional) Integração com GPT Search: O modelo final (ou um step adicional com

GPT-4.1 e GPT Search) pode buscar informações de mercado contextuais (notícias recentes, eventos geopolíticos, sentimento do mercado) para enriquecer a análise técnica com fatores fundamentalistas ou conjunturais.

(Opcional) Uso de Deep Analysis para Cálculos e Projeções: O modelo final (especialmente um como Claude 3.7 Sonnet) pode ser instruído a “consultar fontes e bibliotecas externas para complementar os cálculos e a sua decisão”. Isso ativaria o Deep Analysis, permitindo que a IA:

- Importe bibliotecas Python como pandas, numpy, matplotlib, yfinance, seaborn.

- Baixe dados históricos do ativo (via yfinance).

- Calcule indicadores técnicos (RSI, MACD, Médias Móveis, Bandas de Bollinger) com precisão.

- Realize análises de regressão, identifique níveis de Fibonacci, calcule volatilidade, Sharpe Ratio.

- Determine níveis operacionais (preço de entrada, stop loss, alvos de lucro).

- Sugira alocação de capital com base no perfil de risco.

- Gere gráficos complementares (histogramas, projeções).

Essa abordagem em camadas, onde cada modelo contribui com uma parte da análise, culminando em uma avaliação robusta e, se necessário, quantitativa pelo Deep Analysis, transforma o agente de IA em um poderoso mentor e assistente para análise gráfica. Ele pode não apenas interpretar o gráfico fornecido, mas também buscar dados adicionais, realizar cálculos complexos e apresentar recomendações estratégicas com justificativas detalhadas, sempre com a ressalva de que se trata de uma ferramenta de auxílio à decisão, e não um substituto para o julgamento humano e a gestão de risco. A capacidade de solicitar gráficos ou indicadores faltantes reforça seu papel didático e colaborativo.

7. Conclusão e Perspectivas Futuras

A exploração dos agentes de Inteligência Artificial, desde suas tipologias fundamentais até as aplicações avançadas de agentes multimodelo, revela um campo em constante evolução e com potencial transformador. A capacidade de integrar diferentes modalidades de informação, orquestrar múltiplos modelos de IA e combinar o poder da linguagem natural com a precisão da execução de código (Deep Analysis) está redefinindo o que é possível em áreas como análise de dados, finanças e tomada de decisão estratégica.

Os estudos de caso apresentados, desde o desafio lógico até as complexas análises financeiras e gráficas, demonstram que a abordagem multimodelo frequentemente supera o desempenho de modelos individuais, oferecendo maior robustez, profundidade e confiabilidade. A flexibilidade das plataformas modernas de IA, como a Tess, permite que usuários com diferentes níveis de conhecimento técnico construam e utilizem esses agentes sofisticados, seja através de interfaces de chat intuitivas, seja pela criação de automações mais complexas no Studio ou pela integração com ferramentas externas via APIs e plataformas de workflow.

As implicações são vastas. Profissionais de diversas áreas podem contar com assistentes de IA cada vez mais capazes, que não apenas executam tarefas, mas também auxiliam no raciocínio, na aprendizagem e na descoberta de novos insights. A capacidade de analisar documentos extensos, interpretar dados numéricos, avaliar diferentes perspectivas e comunicar conclusões de forma clara e adaptada são habilidades que potencializam a produtividade e a qualidade do trabalho humano.

Olhando para o futuro, a tendência é que os agentes de IA se tornem ainda mais integrados, autônomos e capazes de aprender com o feedback e com novas informações em tempo real. A convergência de diferentes modelos e capacidades em plataformas unificadas simplificará ainda mais a criação de soluções personalizadas para desafios específicos. O desenvolvimento contínuo de técnicas de prompt engineering, a otimização dos modelos de reasoning e a expansão das bibliotecas e ferramentas acessíveis via Deep Analysis prometem levar os agentes multimodelo a novos patamares de utilidade e inteligência.

A jornada de aprendizado e aplicação da Inteligência Artificial é contínua. O domínio dessas ferramentas e conceitos não é apenas uma vantagem competitiva, mas uma necessidade crescente em um mundo cada vez mais orientado por dados e permeado pela tecnologia. A capacidade de “pensar com a IA”, utilizando-a como uma extensão da nossa própria capacidade cognitiva, será uma das habilidades mais valiosas nas próximas décadas.



Faculdade Mar Atlântico