



ESPECIALISTA EM AGENTES DE IA



Faculdade
Mar Atlântico



Certificação IA

SUMÁRIO

1. O Potencial Transformador da Inteligência Artificial	3
2. A Relevância das Knowledge Bases na Customização de IA.....	3
3. Explorando o Panorama dos Modelos de Inteligência Artificial	3
3.1. A Origem e o Treinamento de Modelos: O Caso dos Modelos Chineses.....	4
3.2. Considerações Éticas e de Privacidade	4
4. Knowledge Bases: Mecanismos de Personalização de IA.....	5
4.1. Introdução aos Modos de Integração: Deep Learning e RAG	6
4.2. O Modo Deep Learning: Retreinando a IA com Memória de Longo Prazo	6
4.3. O Modo RAG (Retrieval Augmented Generation): Busca Vetorizada em Grandes Volumes de Dados	7
4.4. Limitações e Sinergias: Janela de Contexto, RAG e Deep Learning.....	9
5. Análise de Dados Avançada com Inteligência Artificial: O Poder do Deep Analysis..	10
5.1. Superando as Limitações da IA Generativa em Análises Complexas.....	10
5.3. Aplicações Práticas do Deep Analysis.....	11
6. Um Panorama Detalhado dos Modelos de Linguagem de Grande Escala (LLMs).....	12
6.1. Família OpenAI.....	12
6.2. Modelos DeepSeek	13
6.3. Modelos Qwen (Alibaba)	13
6.4. Família Gemini (Google)	14
6.5. Família Claude (Anthropic)	14
6.6. Modelos LLAMA (Meta AI)	15
6.7. Command R (Cohere).....	15
6.8. Modelos Mistral	15
6.9. Considerações sobre Parâmetros, Reasoning e Uso Local	16
7. Desenvolvendo Habilidades e Hábitos para a Era da Inteligência Artificial.....	16
7.1. O Chain of Thought como Ferramenta de Aprendizado.....	16
7.2. A Importância do Hábito e da Postura AI First.....	17

1. O Potencial Transformador da Inteligência Artificial

A inteligência artificial (IA) representa uma revolução tecnológica com a capacidade de potencializar exponencialmente as habilidades humanas. Se compararmos o computador a uma “bicicleta para a mente”, como sugeria Steve Jobs, a IA pode ser vista como um “foguetete para a criatividade humana”. Isso se deve à sua capacidade de permitir que indivíduos realizem tarefas complexas – como escrever textos elaborados, realizar cálculos avançados, desenvolver códigos de programação, criar imagens, vídeos e músicas – mesmo sem possuírem previamente as skills específicas para tais atividades. A IA atua como um multiplicador das capacidades inerentes ao ser humano, sejam elas hard skills (habilidades técnicas) ou soft skills (habilidades comportamentais), elevando o potencial individual a patamares surpreendentes.

Compreender e utilizar profissionalmente a IA envolve diferentes níveis de engajamento. O nível mais elementar consiste em utilizar ferramentas de IA prontas, como um chat conversacional, para interações diretas. Um segundo nível, mais profissional, emerge quando o usuário começa a customizar seus próprios agentes de IA, criando soluções específicas para suas necessidades particulares. Essa customização é fundamental para desbloquear o verdadeiro potencial da IA em contextos profissionais.

2. A Relevância das Knowledge Bases na Customização de IA

Um dos pilares para a customização e o uso profissional da IA é a construção de Knowledge Bases (Bases de Conhecimento). Estas são, sem dúvida, o principal meio para personalizar uma IA, permitindo que ela opere com informações e contextos específicos, alinhados aos objetivos do usuário. Uma IA genérica, por padrão, não possui conhecimento especializado sobre um domínio particular ou sobre as nuances de um negócio específico. Por exemplo, ao interagir com um modelo de linguagem de grande escala (LLM) como o GPT-4o Mini através de uma interface de chat, o usuário está, na verdade, utilizando o modelo base da OpenAI, conectado via API, sem camadas adicionais de treinamento específico da plataforma que intermedeia o acesso.

Isso fica evidente quando se questiona a identidade desses modelos. Um modelo como o GPT-4o Mini, se perguntado “Quem você é?”, responderá que é um modelo de IA criado pela OpenAI. Não haverá, por padrão, uma camada de personalização que o identifique com a plataforma específica que o usuário está utilizando. Essa ausência de treinamento prévio específico da plataforma de acesso garante que o usuário utilize os modelos em sua forma mais pura, sem interferências.

3. Explorando o Panorama dos Modelos de Inteligência Artificial

O mercado de IA é composto por uma diversidade de modelos, cada um com suas características, origens e métodos de treinamento. É crucial entender essas nuances para fazer escolhas informadas e aproveitar ao máximo o potencial de cada ferramenta.

3.1. A Origem e o Treinamento de Modelos: O Caso dos Modelos Chineses

Uma observação interessante surge ao interrogar diferentes modelos sobre sua identidade. Enquanto modelos como o GPT (OpenAI) e Claude (Anthropic) explicitam seus desenvolvedores, alguns modelos, como o Qwen (da Alibaba), podem revelar informações surpreendentes. Em testes, ao ser questionado sobre sua identidade, o Qwen já indicou ter sido criado pela Anthropic, o que sugere que foi treinado ou fine-ajustado utilizando dados ou arquiteturas da Anthropic.

Essa prática não é incomum, especialmente entre alguns modelos chineses. Em vez de desenvolverem modelos inteiramente do zero, o que demanda tempo e recursos significativos, algumas empresas optam por utilizar códigos abertos (open source) e treiná-los ou ajustá-los com base em IAs já estabelecidas e de alta performance. O modelo DeepSeek, por exemplo, ganhou notoriedade e, em interações iniciais, também indicava ter sido treinado com o ChatGPT. Embora correções posteriores possam ter alterado essa auto-identificação, essa abordagem de “aproveitar” modelos existentes é uma estratégia para acelerar o desenvolvimento e alcançar um desempenho competitivo.

É importante ressaltar que o fato de um modelo ser treinado com base em outro – um “puxadinho”, como se costuma dizer informalmente – não o torna inerentemente inferior. Se o treinamento é realizado de forma legal e ética, utilizando recursos permitidos, o resultado pode ser um modelo com alta performance. Contudo, é natural questionar se um modelo treinado a partir de outro pode superar o original. A probabilidade inicial pode ser baixa, pois, na melhor das hipóteses, ele seria uma cópia simplificada. Enquanto empresas como OpenAI e Anthropic investem pesadamente em pesquisa e desenvolvimento para avançar o estado da arte (lançando versões como Claude 3.7 ou futuros Claude 4), esses modelos derivados podem, a princípio, ficar um passo atrás.

No entanto, essa não é a história completa. Menosprezar esses modelos seria um erro. As equipes por trás de modelos como Qwen ou DeepSeek podem adicionar novas camadas de treinamento, dados proprietários e customizações específicas. Podem realizar fine-tuning (otimização) para nichos específicos, como programação (ex: Qwen-Code), e, nesses nichos, potencialmente superar o desempenho dos modelos originais. A estratégia de treinar com modelos estabelecidos pode ser vista como um atalho para atingir um benchmark de qualidade rapidamente, para então construir diferenciais sobre essa base.

3.2. Considerações Éticas e de Privacidade

A discussão sobre modelos de IA, especialmente os de origem chinesa, frequentemente levanta questões políticas e de privacidade que, embora importantes, devem ser analisadas com sobriedade quando o foco é a performance técnica. No entanto, é inegável que diferentes atores no cenário global da IA operam sob diferentes regras e práticas.

Há relatos e evidências de que alguns modelos chineses utilizaram métodos agressivos para coleta de dados da internet, desrespeitando protocolos como o robots.txt (que indica se um site permite ou não o rastreamento por robôs) ou até mesmo tentando acessar áreas logadas de sites. Tais práticas contrastam com a de modelos como o ChatGPT, que, segundo a OpenAI, respeitam essas diretivas. Essas diferenças de abordagem na coleta de dados para treinamento são fatos observados por diversas empresas e usuários, incluindo incidentes de sobrecarga em servidores (DDOS-like attacks) causados por rastreadores intensivos de alguns LLMs chineses.

É crucial não generalizar. O fato de uma IA chinesa ter adotado práticas questionáveis não implica que todas as empresas chinesas do setor o façam. Empresas como a Alibaba, com seu modelo Qwen, podem ter políticas e práticas distintas. A questão da privacidade é central, e plataformas que oferecem acesso a esses modelos, como a TESS AI, buscam garantir a privacidade dos dados do usuário, especialmente quando se trata de modelos open source que podem ser hospedados em infraestrutura própria e controlada. Se a privacidade é garantida, o foco pode retornar à performance e ao potencial de resultados que esses modelos podem oferecer.

Um exemplo notável de contribuição positiva vinda de um modelo chinês foi a abertura do reasoning (capacidade de pensamento passo a passo) pelo DeepSeek. Antes, modelos como o do ChatGPT operavam de forma mais black box em relação ao seu processo de pensamento. O DeepSeek tornou esse histórico de pensamento visível, facilitando a identificação de erros e a correção do reasoning da IA. Essa transparência influenciou o mercado, levando a OpenAI a anunciar planos de abrir mais o reasoning de seus modelos, reconhecendo que o monitoramento desse processo contribui para a qualidade. O Claude 3.5 Sonnet também evoluiu para incluir modelos com reasoning mais explícito.

Em suma, a avaliação de modelos de IA deve considerar a performance, o custo-benefício, as questões de privacidade e as práticas éticas de seus desenvolvedores. A diversidade de modelos, incluindo os chineses, enriquece o ecossistema e impulsiona a inovação, mas exige um olhar crítico e informado por parte dos usuários.

4. Knowledge Bases: Mecanismos de Personalização de IA

As Knowledge Bases são fundamentais para transcender o uso genérico da IA e adaptá-la a contextos e necessidades específicas, elevando significativamente a performance e a relevância dos resultados. Elas permitem que os LLMs, já pré-treinados em vastos volumes de dados, sejam “retreinados” ou personalizados, adquirindo uma identidade única e otimizada para um propósito particular.

Essa capacidade de customização é também uma ferramenta poderosa para combater vieses. A informação disponível na internet e no mundo não é uniformemente distribuída entre todas as perspectivas ideológicas, políticas ou culturais, o que pode levar a vieses nos modelos de IA treinados com esses dados. Ao adicionar uma Knowledge Base específica, o usuário pode direcionar a IA, fornecendo-lhe um conjunto de informações curadas que reflitam a linha de pensamento, os valores ou os conhecimentos técnicos desejados, mitigando assim os vieses indesejados. Por exemplo, um psicólogo que trabalha com uma

linha terapêutica específica pode treinar uma IA com textos e princípios dessa abordagem, garantindo que as interações e recomendações da IA estejam alinhadas com sua prática profissional.

Plataformas avançadas de IA geralmente oferecem múltiplas formas de adicionar conteúdo a uma Knowledge Base, incluindo arquivos de áudio, CSV, código, documentos Word, Excel, planilhas, imagens, PDF, TXT e até mesmo conteúdo extraído de sites via WebScrapper. Essa versatilidade permite que uma ampla gama de informações seja utilizada para personalizar a IA.

Ao adicionar arquivos de áudio, por exemplo, é comum que a plataforma ofereça diferentes modelos de transcrição, como Deepgram, AssemblyAI, OpenAI Whisper ou RevAI. Cada um desses modelos possui performances distintas dependendo de fatores como o sotaque do locutor, a clareza da fala e a presença de pausas ou hesitações. Alguns modelos, como o Deepgram, são conhecidos por sua habilidade em suprimir interjeições e hesitações (“uhm”, “er”), resultando em transcrições mais limpas. A escolha do modelo de transcrição adequado pode, portanto, impactar a qualidade da informação que alimentará a Knowledge Base.

4.1. Introdução aos Modos de Integração: Deep Learning e RAG

Ao integrar informações em uma Knowledge Base, duas abordagens principais se destacam: o modo Deep Learning e o modo RAG (Retrieval Augmented Generation). Compreender a diferença entre esses dois mundos é crucial para utilizar a IA de forma eficaz e otimizada.

Simplificadamente, a arquitetura de interação com uma IA pode ser dividida em três componentes:

O System Prompt: Uma camada de memória de longo prazo, como o “cérebro” da IA, onde instruções persistentes são armazenadas.

O Input: As mensagens e dados que o usuário envia para a IA.

O Output: As respostas e resultados gerados pela IA.

As instruções fornecidas ao configurar um agente de IA em plataformas como a TESS AI são tipicamente inseridas no System Prompt. Essa é uma área de memória que a IA sempre consulta, garantindo que as diretrizes fundamentais sejam lembradas ao longo de toda a interação. Em contraste, as mensagens trocadas no chat (entradas e saídas) compõem uma memória de curto prazo; à medida que a conversa se alonga, a IA pode “esquecer” informações trocadas anteriormente, dependendo do seu limite de janela de contexto.

4.2. O Modo Deep Learning: Retreinando a IA com Memória de Longo Prazo

O modo Deep Learning, quando aplicado a uma Knowledge Base, implica que o conteúdo fornecido (por exemplo, o texto de um PDF ou a transcrição de um áudio) é convertido

em texto e inserido diretamente no System Prompt da IA. Isso significa que a informação se torna parte da memória de longo prazo da IA, como se ela estivesse sendo efetivamente retreinada com aquele conteúdo.

Vantagens do Deep Learning:

A principal vantagem é que a IA internaliza profundamente a informação, utilizando-a como base para todas as suas respostas e comportamentos subsequentes. Isso é ideal para informações cruciais que devem definir a persona, o conhecimento central ou as diretrizes operacionais da IA.

Desafios e Considerações de Custo do Deep Learning:

O desafio reside no impacto sobre o custo e a eficiência. Como a informação no System Prompt é consultada a cada interação, um volume grande de dados nesse local aumenta significativamente a quantidade de tokens (unidades de texto processadas pela IA) enviados à IA a cada mensagem. Por exemplo, se um documento de 5.000 palavras (aproximadamente 5.000 tokens, para simplificar) for adicionado via Deep Learning, esses 5.000 tokens serão reenviados à IA em cada nova pergunta do usuário. Se o usuário fizer 5 perguntas, e cada pergunta tiver, digamos, 50 tokens, e cada resposta 300 tokens, o custo de input apenas do System Prompt seria de 5 perguntas * 5.000 tokens = 25.000 tokens, somados aos tokens das perguntas (5 * 50 = 250) e das respostas (5 * 300 = 1500). O total seria de 26.750 tokens. Sem essa Knowledge Base no System Prompt, o total seria de apenas 1.750 tokens.

Essa diferença substancial de custo explica por que o modo Deep Learning é recomendado para conteúdos “pequenos” ou “leves”, ou seja, informações verdadeiramente fundamentais e concisas. Utilizar o Deep Learning para grandes volumes de dados, como o conteúdo integral de um site (que incluiria menus, rodapés, call to actions e outros textos irrelevantes para o treinamento central), não apenas encareceria a operação, mas também poderia “poluir” o conhecimento da IA com informações desnecessárias ou até mesmo contraproducentes. Por exemplo, treinar uma IA com um call to action como “Teste grátis por 7 dias” pode fazer com que ela recomende essa frase em contextos inadequados.

A diligência é, portanto, essencial ao usar o Deep Learning. Recomenda-se criar um documento separado, cuidadosamente elaborado, contendo apenas as informações cruciais que se deseja imprimir na memória de longo prazo da IA. Para criar uma IA especializada, por exemplo, em medicina ou direito, o ideal é detalhar nesse documento a tarefa da IA, suas fontes de informação primárias, a linha de pensamento que deve seguir, e referências importantes.

É importante notar que muitas ferramentas de IA no mercado, especialmente aquelas com modelos de precificação “ilimitada”, não oferecem a opção de Deep Learning de forma transparente ou robusta. Isso ocorre porque o aumento no volume de tokens de input representa um custo maior para a empresa que fornece o serviço. Plataformas que oferecem precificação transparente e granular geralmente disponibilizam essa funcionalidade, pois convidam o usuário a um uso mais profissional e consciente dos recursos.

4.3. O Modo RAG (Retrieval Augmented Generation): Busca Vetorizada em Grandes Volumes de Dados

O modo RAG opera de maneira drasticamente diferente do Deep Learning e é

particularmente adequado para lidar com grandes volumes de informação, como documentos extensos com centenas de páginas. A principal característica do RAG é que ele não insere todo o conteúdo do documento no System Prompt. Em vez disso, o documento é processado e transformado em um formato que a IA pode consultar eficientemente: vetores.

O Processo de Vetorização no RAG:

Quando um documento é adicionado via RAG, ele passa por um processo chamado vetorização. Isso envolve dividir o documento em pedaços menores (chunks of data) e converter cada pedaço em um vetor numérico que representa seu significado semântico. Esses vetores são armazenados em um banco de dados vetorial. Esse processo de treinamento inicial tem um custo, geralmente baixo, associado à conversão e armazenamento dos vetores. Por exemplo, um documento, mesmo grande, pode custar cerca de 20 créditos para ser treinado e vetorizado em plataformas como a TESS AI.

Como o RAG Funciona na Prática:

Uma vez que o documento está vetorizado, ele se torna uma base de dados consultável pela IA. Quando o usuário faz uma pergunta, a IA converte essa pergunta também em um vetor e busca no banco de dados vetorial os chunks de informação cujos vetores são mais semanticamente similares à pergunta. Os chunks mais relevantes são então recuperados e fornecidos à IA como contexto adicional para que ela formule a resposta.

Vantagens do RAG:

Custo-Eficiência para Grandes Documentos: Como apenas os trechos relevantes são recuperados e enviados à IA a cada consulta (e não o documento inteiro), o custo de tokens por interação é significativamente menor comparado ao Deep Learning com o mesmo volume de dados. O custo principal com RAG após o treinamento inicial é referente aos tokens da pergunta, dos chunks recuperados e da resposta gerada.

Escalabilidade: Permite trabalhar com vastas quantidades de informação que excederiam os limites práticos do System Prompt ou da janela de contexto de muitos modelos.

Foco em Busca e Consulta: O RAG é excelente para encontrar informações específicas dentro de um grande corpo de texto. Se o usuário precisa que a IA encontre estatísticas, definições, ou trechos específicos relacionados a um tema em múltiplos documentos, o RAG é altamente eficaz. A busca vetorizada não é uma simples busca por palavras-chave (como um CTRL+F); ela compreende o significado e o contexto. Por exemplo, se um poema romântico está em um PDF e o usuário pergunta sobre “poesia sentimental”, a IA pode identificar e recuperar aquele trecho devido à similaridade semântica, mesmo que as palavras exatas não coincidam.

Limitações do RAG:

O RAG é primordialmente uma tecnologia de busca e recuperação. Ele não é ideal para tarefas que exigem que a IA processe e compreenda a totalidade de um documento extenso de uma só vez. Por exemplo, pedir um resumo completo de um livro de 500 páginas usando RAG pode não produzir o melhor resultado, pois a IA receberá apenas os chunks que o sistema de busca julgar mais relevantes para a Tarefa “resumir”, e não o livro inteiro. Embora possa tentar, a qualidade pode ser inferior à de uma IA que tivesse acesso ao texto completo de outra forma.

Da mesma forma, perguntas que dependem da estrutura física do documento, como “Qual é o conteúdo do último parágrafo da página 388?”, geralmente não são bem

respondidas pelo RAG. Isso ocorre porque o processo de vetorização divide o texto em chunks semânticos, e a IA perde a noção de paginação ou estrutura de parágrafos original. A IA opera sobre esses chunks, não sobre a formatação visual do documento.

4.4. Limitações e Sinergias: Janela de Contexto, RAG e Deep Learning

Todos os modelos de IA possuem uma “janela de contexto” (context window), que é a quantidade máxima de tokens (informações) que eles conseguem processar em uma única interação ou manter em sua memória de curto prazo. Essa janela varia entre modelos: o ChatGPT-4o Mini pode ter uma janela de 128.000 tokens, o Claude 3 pode chegar a 200.000 tokens, e o Gemini 1.5 Pro a 1 milhão de tokens.

Mesmo dentro dessa janela, a capacidade de “lembrar” ou dar atenção a todas as partes da informação não é perfeita; modelos podem apresentar uma queda no recall (capacidade de recuperação da informação) à medida que se aproximam do limite de sua janela de contexto. Por exemplo, um modelo pode perder 10-15% de eficiência de lembrança ao operar no máximo de sua janela.

Isso tem implicações diretas na análise de dados:

Se um arquivo grande (ex: uma planilha com 300.000 tokens de dados) é submetido a um modelo com janela de 128.000 tokens, o modelo não conseguirá “ver” todos os dados de uma vez, mesmo que fosse usado o modo Deep Learning para tentar forçar a entrada de todos os dados.

Se o mesmo arquivo é submetido via RAG em plataformas como o ChatGPT (que tipicamente usa RAG por padrão para arquivos), a IA tentará extrair apenas um pedaço dos dados para análise, levando a resultados incompletos ou incorretos para tarefas que exigem a visão do todo (ex: “faça uma análise completa desta planilha”).

O Deep Learning permite que a informação seja integralmente considerada pela IA (dentro dos limites da janela de contexto e do custo), tornando-o mais adequado para tarefas que exigem uma compreensão holística de um conjunto de dados menor e crucial. O RAG brilha quando se trata de consultar grandes repositórios de informação de forma eficiente.

A escolha entre Deep Learning e RAG depende, portanto, da natureza da informação, do volume dos dados e do tipo de tarefa que a IA deve executar. Em muitos casos, uma combinação estratégica de ambos pode ser a melhor abordagem: usar Deep Learning para instruções essenciais e a persona da IA, e RAG para vastas bases de conhecimento consultáveis.

A personalização de IA através de Knowledge Bases permite criar agentes especializados, verdadeiros “modelos próprios”, que superam o desempenho de IAs genéricas para tarefas específicas. A compreensão das nuances entre Deep Learning e RAG, juntamente com a gestão da janela de contexto, capacita o usuário a extrair resultados muito mais significativos e precisos da inteligência artificial.

5. Análise de Dados Avançada com Inteligência Artificial: O Poder do Deep Analysis

A inteligência artificial generativa, apesar de seus avanços notáveis, enfrenta dificuldades intrínsecas ao lidar com grandes volumes de dados estruturados e ao executar tarefas que exigem precisão matemática ou lógica procedural complexa. Quando se sobe um arquivo, como uma planilha, para uma IA generativa padrão (como o ChatGPT), ela tipicamente o processa utilizando a tecnologia RAG. Como discutido anteriormente, o RAG envia pedaços de dados (chunks) para a IA, o que é inadequado para análises que requerem a totalidade dos dados.

Por exemplo, solicitar a uma IA generativa que some todos os valores de uma coluna de vendas em uma planilha extensa frequentemente resulta em erro. A IA pode pegar uma amostra dos dados, realizar o cálculo sobre essa amostra e apresentar um resultado incorreto. Mesmo que os dados fossem copiados e colados diretamente no input da IA (tentando contornar o RAG e usando a memória de troca), a IA ainda pode falhar devido a limitações em sua capacidade de processar longas sequências de dados numéricos com precisão ou devido à sua janela de contexto. Em um teste real, ao solicitar o somatório de vendas de uma planilha, o ChatGPT calculou 11.641, quando o valor correto era 998.697, evidenciando que ele operou sobre um pequeno subconjunto dos dados.

5.1. Superando as Limitações da IA Generativa em Análises Complexas

Para superar esses desafios e realizar análises de dados mais profundas e precisas, algumas plataformas de IA avançadas, como a TESS AI, e funcionalidades específicas de outras, como o Advanced Data Analysis (anteriormente Code Interpreter) da OpenAI (disponível em planos pagos) ou a IA chinesa Manus (em beta), oferecem soluções mais robustas. Essas soluções integram a capacidade de executar código, geralmente em Python, em um ambiente virtual.

Essa abordagem, denominada em algumas plataformas como Deep Analysis, permite uma orquestração sofisticada:

A IA generativa é utilizada para entender a solicitação do usuário e gerar um código em Python capaz de realizar a tarefa desejada (ex: somar uma coluna, gerar uma previsão, criar um gráfico).

Esse código é então executado em uma máquina virtual segura.

Bibliotecas de Python relevantes para a tarefa (ex: Pandas para manipulação de dados, Matplotlib para gráficos, Statsmodels para estatísticas) podem ser baixadas e utilizadas nessa máquina virtual.

Se o código encontrar erros durante a execução, a IA pode ser instruída a depurar e tentar abordagens alternativas até que a tarefa seja concluída com sucesso.

O resultado da execução do código é então retornado ao usuário.

Utilizando essa metodologia de Deep Analysis, a mesma tarefa de somar a coluna de vendas da planilha mencionada anteriormente foi executada com sucesso, resultando no

valor correto de 998.697, mesmo em uma planilha com 7.000 células e utilizando um modelo de IA generativa mais antigo (GPT-4o Legacy). Isso demonstra o poder da combinação da IA generativa (para compreensão da linguagem natural e geração de código) com a execução de código tradicional (para precisão e manipulação de dados).

5.2. A Orquestração de Código em Python: Como Funciona o Deep Analysis

O Deep Analysis representa uma fusão entre a IA generativa e a IA tradicional (ou programação clássica). A IA generativa opera com base em previsões e padrões, o que introduz uma certa instabilidade ou imprevisibilidade. Embora possa acertar em uma alta porcentagem das vezes, essa margem de erro é inaceitável para tarefas que exigem exatidão, como cálculos matemáticos ou análises estatísticas rigorosas. Matemática é exata, e uma regressão linear, por exemplo, deve produzir sempre o mesmo resultado para os mesmos dados e parâmetros, não pode variar devido a uma “previsão” diferente da IA generativa.

No Deep Analysis, a IA generativa atua como um “tradutor” e “planejador”:

Ela interpreta a solicitação do usuário em linguagem natural.

Gera um plano de ação, que geralmente envolve escrever um script em Python.

Escreve o script, selecionando as bibliotecas apropriadas.

O agente orquestrador da plataforma (como os agentes da TESS AI) assume a responsabilidade de:

Criar um ambiente de execução seguro (máquina virtual).

Executar o código gerado pela IA.

Gerenciar dependências (baixar bibliotecas).

Capturar os resultados ou erros.

Se houver erro, pode reenviar o problema para a IA generativa, solicitando uma correção ou uma nova abordagem de código. Esse ciclo de tentativa, erro e correção pode se repetir até que uma solução funcional seja encontrada.

Apresentar o resultado final ao usuário.

Essa capacidade de rodar código Python e acessar sua vasta gama de bibliotecas desbloqueia um potencial imenso. Python possui bibliotecas para praticamente qualquer tipo de análise de dados, aprendizado de máquina, visualização, processamento de texto, manipulação de imagens e muito mais.

5.3. Aplicações Práticas do Deep Analysis

As possibilidades abertas pelo Deep Analysis são vastas e transformadoras, permitindo que usuários sem conhecimento profundo de programação realizem tarefas complexas:

Análise de Dados Estruturados: Cálculos precisos em planilhas, como somas, médias, desvios padrão, filtragens complexas e agregações.

Visualização de Dados: Geração de gráficos (barras, linhas, dispersão, etc.) para

representar dados e tendências, utilizando bibliotecas como Matplotlib ou Seaborn.

Modelagem Estatística e Previsão: Implementação de modelos de previsão, como ARIMA (Médias Móveis Autoregressivas Integradas), para prever vendas, demanda ou outras variáveis temporais. A IA pode gerar o código para ajustar o modelo aos dados e plotar as previsões.

Criação de Ferramentas Interativas Simples: Geração de pequenos aplicativos ou jogos, como um jogo da cobrinha, utilizando bibliotecas gráficas como Pygame (embora geralmente limitado a ambientes que suportam tal interatividade ou exportação).

Geração e Manipulação de Arquivos: Criação de GIFs animados, conversão entre formatos de arquivo, edição programática de conteúdo em arquivos (dentro dos limites de output da IA e complexidade da tarefa).

Tarefas de Machine Learning: Execução de tarefas de aprendizado de máquina mais simples, como treinar um modelo de regressão ou classificação em um conjunto de dados fornecido.

Essa integração permite que profissionais de diversas áreas (médicos, advogados, profissionais de marketing, contadores, engenheiros) realizem análises e desenvolvam soluções que antes exigiriam equipes especializadas ou projetos de IA tradicional custosos. A IA generativa democratiza o acesso a essas ferramentas, orquestrando a criação e execução de código de forma intuitiva.

A capacidade de pedir à IA para, por exemplo, “prever as vendas para o próximo mês usando o modelo ARIMA”, e ela não apenas gerar a previsão, mas também o código, um relatório explicativo, tabelas e gráficos, ilustra o salto qualitativo que o Deep Analysis representa. O usuário pode, inclusive, solicitar à IA que explique os diferentes modelos de previsão disponíveis antes de escolher um, aprendendo no processo.

6. Um Panorama Detalhado dos Modelos de Linguagem de Grande Escala (LLMs)

A escolha do modelo de linguagem de grande escala (LLM) adequado é crucial para o sucesso de qualquer projeto de IA. Cada família de modelos e cada variante específica possui características, pontos fortes e fracos que os tornam mais ou menos adequados para diferentes tarefas. Plataformas avançadas de IA, como a TESS AI, oferecem acesso a uma vasta gama desses modelos, permitindo ao usuário selecionar o mais apropriado ou até mesmo utilizar múltiplos modelos em conjunto.

6.1. Família OpenAI

A OpenAI é uma das pioneiras e líderes no desenvolvimento de LLMs. Sua família de modelos GPT (Generative Pre-trained Transformer) evoluiu significativamente:

GPT-3.5 Turbo: Uma versão mais antiga, mas ainda funcional para tarefas mais simples e com bom custo-benefício.

GPT-4 Turbo: Um avanço em relação ao 3.5, com melhorias em capacidade e raciocínio.

GPT-4.0 e GPT-4.0 Latest: O GPT-4.0 introduziu capacidades multimodais (como interpretação de imagens, Vision). O “Latest” é uma versão otimizada do 4.0, frequentemente com performance superior em diversas tarefas. A distinção entre os dois nem sempre é clara em todas as plataformas, mas a versão “Latest” geralmente representa o estado da arte dentro da linha 4.0 e pode ter um custo maior.

GPT-4.5 (ou modelos como GPT-4o, Omni): Representam os avanços mais recentes da geração 4, com foco em interações mais humanas, capacidade de reasoning aprimorada e multimodalidade robusta. Modelos como o GPT-4o são conhecidos por sua habilidade em emular conversas humanas, sendo excelentes para tarefas como atendimento ao cliente ou assistentes virtuais. Apesar de seu alto custo de API (ex: 150 dólares por milhão de tokens de output para certos modelos avançados), o custo total para aplicações específicas, como uma secretária virtual para uma clínica, pode ser vantajoso comparado a soluções tradicionais.

Modelos com Reasoning (Série O1, O3):

O1 e O1 Mini: Foram dos primeiros modelos da OpenAI a destacar a capacidade de reasoning (pensamento passo a passo). Modelos “Mini” (ou small, light) possuem menos parâmetros, resultando em maior velocidade (menor latência) mas, teoricamente, com capacidades mais limitadas em tarefas complexas. No entanto, para prompts específicos, modelos menores podem, paradoxalmente, performar melhor.

O3 Mini e O3 Mini High: São evoluções nos modelos com reasoning, com o “High” sendo otimizado para tarefas que exigem maior capacidade de raciocínio, como tecnologia e programação.

Os modelos com reasoning explícito tendem a ter maior latência (demoram mais para responder) porque executam um processo de pensamento interno. São geralmente melhores para análise matemática, programação e tarefas que exigem planejamento complexo. A OpenAI nem sempre expõe o streaming do processo de pensamento via API, o que pode tornar o reasoning uma “caixa preta” para o usuário final, embora haja uma tendência de maior abertura.

6.2. Modelos DeepSeek

O DeepSeek é um exemplo de modelo chinês que ganhou destaque.

DeepSeek V3: Comparável aos modelos GPT-4o sem reasoning explícito visível ao usuário, oferece respostas rápidas e é adequado para uma ampla gama de tarefas. É conhecido por ter sido treinado, em parte, com dados do ChatGPT, mas desenvolveu características próprias.

DeepSeek R1 e R1 Small: São as versões com reasoning. O “R1 Small” é a variante mais leve. A grande contribuição do DeepSeek foi a transparência no seu processo de reasoning, permitindo que os usuários visualizassem o histórico de pensamento do modelo, o que é valioso para depuração e compreensão.

6.3. Modelos Qwen (Alibaba)

Os modelos Qwen, desenvolvidos pela Alibaba, também seguem um caminho de performance interessante, geralmente sem expor um reasoning complexo ao usuário final.

São conhecidos pela velocidade e eficiência em tarefas cotidianas.

Qwen Coder: É uma variante especializada e otimizada para tarefas de programação, destacando-se pela rapidez na geração de código. É uma opção de excelente custo-benefício, muitas vezes oferecida de forma ilimitada em plataformas que o integram.

6.4. Família Gemini (Google)

O Google Gemini representa a evolução dos esforços do Google em IA, superando o antigo modelo Bard.

Gemini 1.5 Flash e 1.5 Pro: Marcaram uma mudança significativa na qualidade dos modelos do Google. “Flash” é a designação para modelos mais leves e rápidos (análogos ao “Mini” da OpenAI ou “Small” do DeepSeek), enquanto “Pro” indica versões mais robustas. É importante que as plataformas especifiquem qual versão está sendo usada, pois há diferenças de custo e capacidade.

Gemini 2.0 (Flash, Pro, e Advanced): Representam um salto qualitativo, posicionando o Gemini como um competidor de ponta. O Gemini 2.0 Flash já demonstrava capacidades impressionantes.

Gemini 2.0 Advanced (anteriormente Ultra) e modelos com Thinking: O termo “Thinking” no contexto do Gemini é análogo ao reasoning. Modelos como o Gemini 1.5 Flash with Google Search grounding ou futuras versões avançadas com reasoning explícito são muito promissores. O Gemini 2.0 Advanced, por exemplo, é um modelo altamente capaz, competindo diretamente com os melhores modelos da OpenAI e Anthropic em uma ampla gama de tarefas, desde criatividade até análise complexa. Modelos Gemini em beta podem ter limites de execução, levando a falhas ocasionais se a demanda global exceder a capacidade liberada.

6.5. Família Claude (Anthropic)

A Anthropic é conhecida por seu foco em segurança e IA constitucional. Seus modelos Claude são altamente competitivos:

Claude 3 (Haiku, Sonnet, Opus):

Haiku: O modelo mais leve e rápido, ideal para tarefas que exigem agilidade.

Sonnet: Um modelo intermediário, equilibrando capacidade e velocidade.

Opus: O modelo mais robusto e capaz da família Claude 3, excelente para tarefas complexas.

Claude 3.5 (Haiku, Sonnet): Evoluções que trouxeram melhorias. O Claude 3.5 Sonnet, por exemplo, demonstrou capacidades superiores ao Opus em alguns benchmarks, apesar de ser teoricamente de um nível “médio”. A Anthropic pode lançar atualizações para modelos específicos (como Sonnet) antes de outros na mesma família.

Claude 3.7 Sonnet: Indica a contínua evolução, com foco em aprimorar modelos específicos. A ausência de um “3.7 Opus” ou “3.7 Haiku” no momento do lançamento do 3.7 Sonnet ilustra como as famílias de modelos podem evoluir de forma não uniforme.

Modelos Claude são geralmente fortes em escrita criativa, resumo, análise de texto longo e tarefas que exigem nuances e compreensão contextual profunda.

6.6. Modelos LLAMA (Meta AI)

Desenvolvidos pela Meta AI, os modelos Llama são open source e vêm em várias dimensões, indicadas pelo número de parâmetros:

Llama 3 (8B, 70B): Anteriormente havia versões como Llama 2 com 7B, 13B, 70B. A nomenclatura agora foca em 8B e 70B para Llama 3. Parâmetros (B = bilhões) indicam a complexidade do modelo. Modelos com menos parâmetros (ex: 8B) são mais leves e rápidos, adequados para tarefas simples, traduções e operações cotidianas. Modelos com mais parâmetros (ex: 70B) são mais pesados, mais lentos, mas geralmente mais capazes em tarefas complexas como programação, matemática e geração de insights. O Llama 3 70B é um modelo muito capaz e genérico. Antigamente, existiam modelos experimentais com centenas de bilhões de parâmetros, como o Llama 405B, que seria um modelo muito pesado e potente.

Os modelos Llama são versáteis, mas, em geral, podem ser considerados em uma prateleira de performance ligeiramente abaixo dos modelos de ponta da OpenAI, Anthropic e Google para tarefas muito genéricas, embora se destaquem em cenários específicos, especialmente considerando sua natureza open source.

6.7. Command R (Cohere)

A Cohere foca em soluções de IA para empresas (enterprise).

Command R e Command R+: São modelos robustos, conhecidos por sua performance excepcional em tarefas específicas, muitas vezes superando outros LLMs de ponta nesses nichos. No entanto, sua performance pode ser inconsistente em tarefas mais genéricas, sendo um modelo de “amor e ódio” para alguns usuários. A Cohere trabalha com grandes corporações, e seus modelos são otimizados para casos de uso empresariais.

6.8. Modelos Mistral

A Mistral AI, uma empresa francesa, ganhou destaque com modelos open source eficientes e leves.

Mistral 7B e Mixtral 8x7B: São exemplos de modelos que oferecem excelente performance para seu tamanho. São muito rápidos e ideais para aplicações que exigem baixa latência e custo, como renomear arquivos, traduções rápidas, e funcionalidades de IA embarcadas em outras plataformas (HubSpot, Notion, Slack frequentemente utilizam modelos como Llama ou Mistral para essas tarefas).

A Mistral também está desenvolvendo modelos mais robustos (Mistral Large), buscando competir em capacidade com os LLMs de ponta, o que pode posicioná-los em prateleiras superiores no futuro.

6.9. Considerações sobre Parâmetros, Reasoning e Uso Local

Parâmetros: Um maior número de parâmetros geralmente implica maior capacidade, mas também maior custo de treinamento e inferência, maior latência e maior consumo de recursos computacionais (CPU/GPU). Não garante, por si só, melhor performance em todos os prompts; modelos menores podem ser superiores para tarefas específicas.

Reasoning: Modelos com capacidade de reasoning explícito (como as séries O da OpenAI, R do DeepSeek, ou com Thinking do Gemini) são projetados para pensar passo a passo. Isso aumenta a latência (tempo de resposta pode ir de milissegundos para minutos), mas pode melhorar a qualidade em tarefas complexas.

Uso Local de Modelos Open Source: Embora seja tecnicamente possível instalar modelos open source (como Llama ou Mistral) localmente, rodar modelos robustos (com muitos parâmetros) exige hardware **caro** (placas de vídeo potentes, muita memória RAM). Muitos tutoriais que promovem o uso local “gratuito” referem-se a modelos muito leves, com capacidades limitadas. Para modelos de alta performance, o custo do hardware dedicado geralmente supera em muito o custo de usar esses modelos via API ou em plataformas de IA.

A diversidade de LLMs é uma vantagem, mas apenas se o usuário puder acessá-los, testá-los e, idealmente, combiná-los. Plataformas que permitem o uso simultâneo de múltiplos modelos e aprendizado entre eles (onde um modelo pode criticar ou refinar a saída de outro) maximizam o benefício dessa diversidade.

7. Desenvolvendo Habilidades e Hábitos para a Era da Inteligência Artificial

A inteligência artificial não é apenas uma nova ferramenta; é uma transformação fundamental na maneira como trabalhamos, aprendemos e interagimos com a informação. Para navegar e prosperar nesta nova era, é essencial desenvolver não apenas o conhecimento técnico sobre IA, mas também hábitos e posturas mentais que permitam extrair o máximo de seu potencial.

7.1. O Chain of Thought como Ferramenta de Aprendizado

Um dos frameworks mais poderosos para interagir com a IA e, crucialmente, para o aprendizado humano, é o Chain of Thought (CoT), ou Cadeia de Pensamento. O CoT é a base do reasoning em IAs: em vez de apenas fornecer uma resposta final, a IA é instruída a detalhar o processo passo a passo que a levou àquela solução.

Quando solicitamos à IA que resolva um problema (seja uma equação matemática, uma

previsão de vendas usando o sistema ARIMA, ou a análise de um caso complexo) e que explique seu raciocínio passo a passo, transformamos a IA em um tutor personalizado. Ela não apenas entrega o resultado, mas desmembra o problema em etapas menores e explica cada uma delas. Isso permite ao usuário:

Compreender o Processo: Entender a lógica por trás da solução, não apenas a solução em si.

Aprender Novas Habilidades: A IA pode ensinar virtualmente qualquer tópico que domine, desde conceitos de física e matemática até técnicas de escrita ou programação.

Identificar Erros: Tanto na IA quanto no próprio entendimento do usuário. Se a IA cometer um erro em seu raciocínio, o CoT o torna visível. Se o usuário não entende uma etapa, pode pedir mais esclarecimentos sobre aquele ponto específico.

Estimular o Pensamento Crítico: Ao analisar o CoT de diferentes modelos sobre o mesmo problema (por exemplo, pedir ao Gemini para analisar criticamente a solução passo a passo do ChatGPT), o usuário pode obter múltiplas perspectivas e aprofundar sua compreensão das nuances de cada abordagem.

O CoT democratiza o acesso ao conhecimento. Para qualquer profissional, independentemente do nível de experiência ou da área de atuação, a capacidade de pedir à IA “me explique como se eu fosse uma criança de 7 anos” sobre um conceito complexo (como blockchain ou criptomoedas) e, a partir daí, aprofundar o questionamento, desbloqueia um modo de aprendizado contínuo e autodirigido. É como ter o melhor professor particular do mundo disponível a qualquer momento.

7.2. A Importância do Hábito e da Postura AI First

O maior desafio para a adoção generalizada e eficaz da IA não é, muitas vezes, a tecnologia em si, nem a complexidade do conhecimento necessário, mas sim a formação de novos hábitos. Assim como o computador, o celular e a internet enfrentaram uma curva de adoção inicial ligada à mudança de hábitos, a IA também exige uma nova rotina de interação.

Desenvolver o hábito de:

Recorrer à IA: Para pesquisar, conversar, trocar ideias, testar soluções.

Ser Curioso: Perguntar, explorar diferentes modelos, experimentar prompts variados.

Adotar uma mentalidade AI First: Considerar a IA como um ponto de partida ou um colaborador primário em diversas tarefas, em vez de um último recurso.

Para profissionais que buscam se recolocar no mercado ou alavancar suas carreiras, a IA oferece uma oportunidade sem precedentes. A complexidade técnica para o uso básico e intermediário não é proibitiva; a maior barreira pode ser a inércia ou uma postura de uso mínimo (“vou usar porque é importante, mas não quero gastar meu tempo com isso”). Essa postura pode ser limitante em um momento de revolução tecnológica.

É crucial encarar a IA com seriedade profissional, estabelecendo metas para sua integração na vida profissional e, quando aplicável, pessoal. Por exemplo, definir o objetivo de criar um certo número de agentes de IA personalizados ou de construir Knowledge Bases para projetos específicos até o final do mês. Quanto mais imersão e prática neste momento,

maior será a proficiência e a capacidade de liderar a adoção da IA em sua respectiva área.

A atual revolução da IA é particularmente notável por sua acessibilidade global. Profissionais em qualquer parte do mundo estão enfrentando desafios e oportunidades semelhantes. Isso significa que, com dedicação e o desenvolvimento dos hábitos corretos, é possível alcançar níveis de excelência e inovação com impacto global, independentemente da localização geográfica.

A inteligência artificial é uma jornada de aprendizado contínuo. Cultivar a curiosidade, a disciplina para formar novos hábitos e a disposição para explorar profundamente as capacidades da IA são os verdadeiros diferenciais para quem deseja não apenas se adaptar, mas prosperar na era da inteligência artificial.



Faculdade Mar Atlântico